

Predicción de Costos Médicos

Análisis Comparativo entre Regresión Lineal Múltiple y Árboles de Decisión

ÍNDICE

1. Introducción	2
2. Proceso KDD y Análisis Exploratorio de Datos (EDA)	2
2.1. Carga y Estructura de los Datos	2
2.2. Estadística Descriptiva de las Variables	3
2.3. Análisis de Variables Categóricas	4
2.4. Análisis Visual	4
2.4.1. Distribución de variable objetivo	4
2.4.2. Distribución de la Edad (Age)	6
2.4.3. Distribución del Índice de Masa Corporal (BMI)	8
2.4.4. Distribución de hijos	9
2.4.4. Análisis Visual de Variables Categóricas (Smoker, Sex y Region)	11
2.5. Análisis Exploratorio Bivariado	12
2.5.1. Impacto del Tabaquismo de los Costos Médicos	12
2.5.2. Relación entre Género y Cargos Médicos	13
2.5.3. Influencia de la Región Geográfica en los costos	15
2.5.4. Relación entre Dependientes y Costos Médicos	16
2.5.5. Correlación Multivariable: Edad, Tabaquismo y Costos Médicos	18
2.5.6. Interacción de Riesgo: Índice de Masa Corporal (BMI) y Tabaquismo	19
3. Preprocesamiento y Transformación de Datos	21
3.1. Codificación de Variables Categóricas	21
3.2. Depuración y Escalado de Características	22
3.3. Análisis de Correlación Lineal	24
3.4. Verificación de Multicolinealidad Mediante VIF	26
4. Selección y Entrenamiento de Modelos	27
4.1. Modelo Base: Regresión Lineal Múltiple	27
4.2. Modelo Principal: Árbol de Decisión	30
5. Evaluación y Comparación de Rendimiento	32
6. Conclusión	34

1. Introducción

En la industria de las aseguradoras, la capacidad de anticipar y estimar con precisión los costos médicos es un factor determinante para la optimización de planes, la personalización de primas y la gestión del riesgo financiero. Para abordar ese desafío desde una perspectiva analítica, el presente proyecto aplica de manera exhaustiva la metodología de Descubrimiento de Conocimiento en Bases de Datos (KDD, por sus siglas en inglés) para la posterior selección de un modelo de aprendizaje automático.

El conjunto de datos analizado (*Insurance Dataset*) consta de 1338 observaciones y 7 variables que detallan características demográficas y de estilo de vida de los asegurados: edad (*age*), sexo (*sex*), índice de masa corporal (*bmi*), número de dependientes (*children*), condición de fumador (*smoker*), región (*region*) y los costos médicos facturados (*charges*).

El alcance de este reporte documenta la primera fase del proyecto. Se detalla el proceso completo de exploración, la selección y entrenamiento del modelo predictivo base, y concluye con la evaluación de su rendimiento. Adicionalmente, se establecen las bases para trabajos futuros mediante la propuesta de mejoras centradas en el ajuste de hiper parámetros, reservando la implementación de técnicas más complejas para fases posteriores.

2. Proceso KDD y Análisis Exploratorio de Datos (EDA)

El proceso de Descubrimiento de Conocimiento en Base de Datos (KDD) comienza con la selección y comprensión del conjunto de datos. Para este proyecto, el entorno de trabajo se configuró en R utilizando la biblioteca *tidyverse*, la cual facilita la manipulación y visualización eficiente de los datos.

```
> library(tidyverse)
> setwd("/Users/alejandrojuarezrojas/Downloads/ML")
> insurance_data <- read.csv("insurance.csv")
```

2.1. Carga y Estructura de los Datos

El conjunto de datos original consta de 1338 observaciones y 7 variables. Mediante un análisis estructural inicial con la función *str()*, se identificaron cuatro variables numéricas (*age*, *bmi*, *children*, *charges*) y tres categóricas (*sex*, *smoker*, *region*).

```
> str(insurance_data)
'data.frame': 1338 obs. of 7 variables:
 $ age : int 19 18 28 33 32 31 46 37 37 60 ...
 $ sex : chr "female" "male" "male" "male" ...
 $ bmi : num 27.9 33.8 33 22.7 28.9 ...
 $ children: int 0 1 3 0 0 0 1 3 2 0 ...
 $ smoker : chr "yes" "no" "no" "no" ...
 $ region : chr "southwest" "southeast" "southeast" "northwest" ...
 $ charges : num 16885 1726 4449 21984 3867 ...
```

Para verificar la correcta lectura de la información, se inspeccionaron los primeros registros del conjunto de datos mediante la función *head()*:

```
> head(insurance_data)
  age    sex    bmi children
smoker region charges 1   19 female 27.900      0
yes southwest 16884.924 2   18  male 33.770      1
no  southeast 1725.552
3   28  male 33.000      3   no  southeast 4449.462
```

4	33	male	22.705	0	no northwest	21984.471
5	32	male	28.880	0	no northwest	3866.855
6	31	female	25.740	0	no southeast	3756.622

La variable *charges* representa los costos médicos facturados por el seguro, confirmándose como la variable dependiente (variable objetivo o *target*). Dado que se busca predecir un valor numérico continuo, representando una magnitud monetaria en lugar de una categoría discreta, el problema se abordará mediante un modelo de Regresión. El propósito de este modelo no es clasificar a los pacientes en grupos, sino encontrar el patrón matemático que conecta las características de cada persona (como su edad o salud) con el costo médico que va a generar. Esto nos permite trazar una línea o tendencia de ajuste que nos ayude a calcular estimaciones precisas para nuevos asegurados, buscando siempre que la diferencia (el error) entre nuestra predicción y el costo real sea la más pequeña posible.

2.2. Estadística Descriptiva de las Variables

Para comprender la distribución de la información, se extrajeron las estadísticas descriptivas principales utilizando *summary()*:

```
> summary(insurance_data)
      age      sex
      bmi      children smoker
Min.   :18.00  Length:1338   Min.   :15.96  Min.   :0.000
Length:1338
1st Qu.:27.00  Class  :character  1st Qu.:26.30  1st Qu.:0.000  Class
:character
Median :39.00  Mode   :character  Median :30.40  Median :1.000  Mode
:character
Mean   :39.21
3rd Qu.:51.00
Qu.:2.000    Max.    :64.00
:53.13    Max.    :5.000
Length:1338  Min.    : 1122
Class :character  1st Qu.: 4740
Mode   :character  Median : 9382
                Mean   :13270
                3rd Qu.:16640
                Max.    :63770
region
charges
```

A partir de esta salida, se identificaron los siguientes patrones clave:

- **Edad (*age*):** Rango entre 18 y 64 años. La mediana de 39 y la media de 39.21 indican una distribución bastante simétrica.
- **Índice de Masa Corporal (*bmi*):** El análisis de cuartiles ($Q_1 = 26,30$, $Q_3 = 34,69$) y el valor máximo (53.13) indican que una porción significativa de la muestra presenta obesidad.
- **Dependientes (*children*):** La mayoría de los asegurados (más del 75%, según el Q_3)

tiene 2 dependientes o menos.

- **Cargos (*charges*):** Presenta una media (\$13,270) considerablemente mayor que su mediana (\$9,382) y un valor máximo atípico de \$63,770. Esto sugiere que una minoría de clientes representa un costo desproporcionadamente alto.

2.3. Análisis de Variables Categóricas

Para evaluar posibles sesgos antes de la transformación de datos, se revisó la frecuencia de las variables categóricas:

```
> table(insurance_data$sex)

female      male
662      676

> table(insurance_data$smoker)

no  yes
1064 274

> table(insurance_data$region)

northeast northwest southeast southwest
324      325      364      325
```

La muestra presenta un equilibrio casi perfecto en género y distribución geográfica. Por otro lado, aunque los fumadores son una minoría (aproximadamente 20%), constituyen una muestra representativa y suficiente para que el modelo identifique su impacto en la predicción de los costos médicos.

2.4. Análisis Visual

Una vez comprendida la estadística descriptiva general, se procedió a realizar un análisis visual de las distribuciones individuales para identificar patrones, sesgos y posibles agrupaciones subyacentes. Este proceso se llevó a cabo utilizando la librería *ggplot2* de R.

2.4.1. Distribución de variable objetivo

El análisis visual comenzó con la variable dependiente *charges*, que representa el costo médico facturado. Para ello, se generó un histograma con rangos (bins) de \$2,000 USD. La elección de esta magnitud, permite agrupar los gastos en bloques financieros legibles y ofrece un equilibrio visual óptimo. Este tamaño de intervalo es lo suficientemente fino para revelar patrones subyacentes críticos, como agrupaciones secundarias de alto costo sin fragmentar tanto la información que la tendencia general se pierda en el ruido estadístico.

```
> library(ggplot2)
> ggplot(insurance_data, aes(x = charges)) +
+   geom_histogram(binwidth = 2000, fill = "#0073C2FF", color =
+   "black") +
```

```
+ labs(title = "Distribución de charges", x = "Charges (USD)", y
= "Frecuencia")
```




Figura 1. Histograma de frecuencia de los cargos médicos facturados (*charges*).

Al observar la Figura 1, se pueden extraer conclusiones críticas sobre la naturaleza de los costos médicos:

- **Asimetría Positiva (Sesgo a la derecha):** La gran mayoría de los beneficiarios concentra sus gastos en el rango inferior, específicamente entre los \$0 y \$15,000 USD. La “cola” de distribución se extiende fuertemente hacia la derecha, alcanzando valores superiores a los \$60,000 USD.

- **Comportamiento Bimodal:** Se observa un ligero repunte o segunda agrupación de datos en el intervalo de \$35,000 a \$49,000 USD. Este comportamiento bimodal sugiere que la población no es homogénea y que existe al menos una variable categórica que segmenta a los pacientes en dos perfiles de riesgo distintos.

Aunque los valores por encima de los \$40,000 USD presentan una frecuencia baja y podrían considerarse atípicos (*outliers*) desde una perspectiva estrictamente estadística, en el contexto del negocio asegurador representan eventos clínicos reales y de alto impacto financiero. Por lo tanto, se ha determinado no eliminarlos del conjunto de datos, ya que el modelo predictivo debe ser capaz de identificar y estimar estos perfiles de alto riesgo.

2.4.2. Distribución de la Edad (Age)

Posteriormente, se analizó la variable *age* para entender la estructura demográfica de los asegurados. Se generó un histograma agrupando las edades en intervalos de 5 años. Esta decisión metodológica se fundamenta en la práctica analítica del sector salud, donde el riesgo clínico no suele variar drásticamente de un año a otro, pero sí muestra cambios acumulativos significativos en bloques quinquenales. Adicionalmente, dividir el rango total de edades (de 18 a 64 años) en estos segmentos crea una distribución visual limpia que elimina el "ruido" estadístico de las fluctuaciones anuales, permitiendo identificar de forma clara qué grupos generacionales dominan la cartera de clientes.

```
> ggplot(insurance_data, aes(x = age)) +  
+   geom_histogram(binwidth = 5, fill = "#0073C2FF", color =  
"black") +  
+   labs(title = "Distribución de edad", x = "Edad", y =  
"Frecuencia")
```




Figura 2. Histograma de frecuencia para la edad de los asegurados (*age*).

El análisis visual de la Figura 2 revela los siguientes comportamientos demográficos:

- **Concentración en adultos jóvenes:** Se observa un pico atípico de alta frecuencia en el primer intervalo (alrededor de los 18 a 22 años). Dado que la edad mínima registrada es de 18 años, esta sobredensidad es característica de la incorporación de nuevos adultos al sistema de aseguramiento, ya sea como titulares primerizos o por término de cobertura como dependientes en planes familiares.
- **Distribución casi uniforme:** Descartando el pico inicial, la frecuencia de asegurados se mantiene notablemente estable y uniforme desde mediados de los 20s hasta finales de los 50s. Esta es una característica sumamente positiva del conjunto de datos, ya que garantiza que el modelo predictivo no estará sesgado y contará con suficientes observaciones para generalizar el aprendizaje en la mayor parte de la vida adulta de los clientes.

Se nota una disminución abrupta en el último bloque (mayores de 60 años). Retomando la estadística descriptiva, la edad máxima en el conjunto de datos es de 64 años. Este corte

abrupto suele coincidir con la edad de jubilación o la transición a programas de salud gubernamentales (como Medicare en [EE.UU.](#)), lo que explica la menor frecuencia y el fin del registro poblacional en esta aseguradora privada.

2.4.3. Distribución del Índice de Masa Corporal (BMI)

La tercera variable continua fue el Índice de Masa Corporal (*bmi*), un indicador fundamental de la salud metabólica de los asegurados. Se construyó un histograma utilizando rangos de 2 unidades de BMI.

```
> ggplot(insurance_data, aes(x = bmi)) +  
+   geom_histogram(binwidth = 2, fill = "#868686FF", color =  
+   "black") +  
+   labs(title = "Distribución de BMI", x = "BMI", y =  
+   "Frecuencia")
```




Figura 3. Histograma de frecuencia del Índice de Masa Corporal (*bmi*)

Al evaluar la Figura 3, se destacan hallazgos cruciales tanto desde la perspectiva estadística como desde la del riesgo médico:

- **Distribución Normal:** A diferencia de las variables anteriores, el *bmi* presenta una distribución simétrica casi perfecta, asemejándose a una campana de Gauss clásica. Esta normalidad paramétrica es una característica ideal para el modelo predictivo, ya que cumple con los supuestos fundamentales de algoritmos como la regresión lineal múltiple.
- **Desplazamiento hacia el riesgo clínico:** Aunque la distribución es estadísticamente “normal”, no representa a una población clínicamente sana. Según los parámetros de la Organización Mundial de la Salud (OMS), un BMI saludable oscila entre los 18.5 - 24.9. Cómo se observa en el gráfico, la mayor concentración de los datos (*bulk*) se encuentra en el intervalo de 27 a 34.
- **Impacto en la aseguradora:** Dado que la media poblacional se sitúa por encima de 30 (umbral de obesidad clínica), se concluye que la gran mayoría de clientes de esta aseguradora padece de sobrepeso u obesidad. Este hallazgo es un indicador crítico en la fase exploratoria, ya que sugiere que el *bmi* será una de las variables predictoras más fuertes para explicar el incremento en los cargos médicos.

2.4.4. Distribución de hijos

A continuación, se analizó la variable *children*, la cual indica el número de hijos o dependientes cubiertos por la póliza de seguro médico. Dado que se trata de una variable numérica discreta, se transformó temporalmente a factor lógico (*factor()*) dentro de la visualización para generar un gráfico de barras, garantizando así la representación estadística adecuada.

```
> ggplot(insurance_data, aes(x = factor(children))) +  
+   geom_bar(fill = "#EFC000FF") +  
+   labs(title = "Distribución de número de hijos",  
+         x = "Número de hijos", y = "Frecuencia")
```




Figura 4. Gráfico de barras mostrando la frecuencia de dependientes por asegurado.

La inspección de la Figura 4 arroja las siguientes conclusiones sobre la estructura familiar de la cartelera de clientes:

- **Comportamiento monótonamente decreciente:** La gráfica presenta una clara forma de escalón descendente. La moda de la distribución es cero, indicando que el segmento más grande de la población no tiene dependientes registrados en su póliza.
- **Predominancia de coberturas individuales:** La acumulación de frecuencias en los valores 0 y 1 sugiere fuertemente que la base de datos está dominada por planes de salud individuales o de familias pequeñas.
- **Sesgo positivo pronunciado:** Conforme aumenta el número de hijos (2, 3, 4 y 5), la frecuencia decae drásticamente. Las familias con 4 o 5 dependientes representan una fracción mínima (marginal) del conjunto de datos. Para efectos del modelo predictivo de regresión, sería interesante evaluar si el aumento de dependientes tiene un impacto lineal en los cargos o si el incremento de costos es marginal tras el primer hijo.

2.4.4. Análisis Visual de Variables Categóricas (Smoker, Sex y Region)

Para finalizar la exploración univariada, se generaron gráficos de barras para las tres variables categóricas del conjunto de datos. Si bien la frecuencia exacta ya se había validado numéricamente mediante tablas de contingencia, la representación visual consolida el análisis de balanceo de clases.

```
> ggplot(insurance_data, aes(x = smoker)) +  
+   geom_bar(fill = "#CD534CFF") +  
+   labs(title = "Distribución de fumadores", x = "Fumador", y =  
+     "Frecuencia")
```

```
> ggplot(insurance_data, aes(x = sex)) +  
+   geom_bar(fill = "#0073C2FF") +  
+   labs(title = "Distribución por sexo", x = "Sexo", y =  
+     "Frecuencia")
```

```
> ggplot(insurance_data, aes(x = region)) +  
+   geom_bar(fill = "#868686FF") +  
+   labs(title = "Distribución por región", x = "Región", y =  
+     "Frecuencia")
```




Figura 5. Distribución de frecuencias para las variables categóricas: Condición de fumador, Sexo y Región geográfica.

Al evaluar las distribuciones en la Figura 5, se concluye tres aspectos fundamentales para el modelado:

- **Tabaquismo (*smoker*):** Se reafirma la predominancia de pacientes no fumadores. No obstante, en el contexto clínico y actuarial, una muestra cercana al 20% de fumadores es altamente representativa y estadísticamente suficiente para que un modelo de regresión identifique patrones, dado que el tabaquismo suele ser un predictor con un peso altísimo en los costos médicos.

- **Género (*sex*):** Las barras muestran una altura prácticamente idéntica, lo que descarta de manera visual cualquier sesgo de género en el muestreo. La base de datos es perfectamente equitativa en este aspecto.
- **Región geográfica (*region*):** Se observa una distribución homogénea entre las cuatro zonas geográficas del país. Existe un incremento marginal en la región *southeast*, pero esta diferencia es estadísticamente insignificante y no constituye un desbalance de clases que pueda mermar la capacidad predictiva del algoritmo.

2.5. Análisis Exploratorio Bivariado

Tras comprender la distribución individual de cada atributo, la siguiente fase del KDD consistió en un análisis bivariado para evaluar la relación directa de las variables predictoras con la variable objetivo (*charges*). Para ello, se utilizaron diagramas de caja (*boxplots*) y gráficas de dispersión, dependiendo de la naturaleza de cada variable.

2.5.1. Impacto del Tabaquismo de los Costos Médicos

El primer análisis exploró la relación entre la condición de fumador (*smoker*) y los cargos facturados por la aseguradora. Para visualizar la dispersión y los estadísticos de tendencia central en ambos grupos, se construyó un diagrama de caja.

```
> ggplot(insurance_data, aes(x = smoker, y = charges)) +
+   geom_boxplot(fill = "#EFC000FF") +
+   labs(title = "Charges por nivel de tabaquismo",
+         x = "Fumador", y = "Charges (USD)")
```

Al inspeccionar la Figura 6, el hallazgo más contundente es la drástica separación de los costos entre ambos grupos poblacionales. La línea horizontal central dentro de cada caja, la cual representa la mediana de la distribución, indica que el 50% de los pacientes fumadores incurre en gastos superiores a los \$35,000 USD aproximadamente. En contraste, la mediana del grupo de no fumadores se mantiene considerablemente baja, situándose por debajo de los \$10,000 USD. Resulta notable que el límite inferior del rango intercuartílico de los fumadores es superior al límite máximo de los no fumadores (excluyendo valores atípicos). Esta marcada diferencia confirma que el tabaquismo es, hasta el momento, el predictor más fuerte para el aumento exponencial de los cargos médicos.

Por otro lado, el diagrama revela una cantidad significativa de valores atípicos (*outliers*) en el grupo de no fumadores, representados por los puntos individuales en la región superior del gráfico. Aunque desde una perspectiva estrictamente estadística estos puntos escapan de la distribución estándar, en el contexto del dominio del negocio representan eventos clínicos reales y de alto impacto financiero, tales como accidentes severos o padecimientos crónicos no ligados al consumo de tabaco. Por consiguiente, se ha tomado la decisión metodológica de conservar estos registros en el conjunto de entrenamiento, garantizando que el modelo predictivo sea capaz de generalizar y contemplar escenarios de alto costo en pacientes sin factores de riesgo evidentes.




Figura 6. Diagrama de caja de los costos médicos segmentados por la condición de fumador del asegurado.

2.5.2. Relación entre Género y Cargos Médicos

Continuando con el análisis de variables categóricas, se evaluó el impacto del género (*sex*) sobre los costos médicos facturados. El objetivo fue determinar si existía una diferencia estadísticamente significativa en el perfil de gastos entre hombres y mujeres que pudiera influir en el modelo predictivo.

```
> ggplot(insurance_data, aes(x = sex, y = charges)) +  
+   geom_boxplot(fill = "#868686FF") +  
+   labs(title = "Charges por sexo", x = "Sexo", y = "Charges  
(USD)")
```




Figura 7. Distribución de los cargos médicos segmentados por el género del asegurado.

Al analizar la Figura 7, la evidencia visual sugiere que el género no es un factor fuertemente discriminatorio respecto a los cargos base. Las medianas de ambos grupos se ubican en un nivel muy similar, cercano a los \$10,000 USD, y los rangos intercuartílicos (IQR) muestran una superposición casi total. Esto indica que, para la mayoría de la población promedio, el costo médico no varía drásticamente por ser hombre o mujer. El grupo masculino presenta una ligera elongación en el tercer cuartil y posee el valor atípico máximo absoluto del conjunto de datos (superando los \$60,000 USD), lo cual es congruente con la literatura actuarial que asocia a los varones con una mayor incidencia de accidentes de alto impacto.

No obstante, el hallazgo más relevante reside en la concentración de valores atípicos. El grupo femenino exhibe una mayor densidad de observaciones atípicas agrupadas en el segmento de \$30,000 a \$50,000 USD. Desde la perspectiva del dominio de la salud, esta acumulación es un comportamiento esperado, ya que este rango de costos suele correlacionarse con eventos médicos específicos de la población femenina, predominantemente aquellos relacionados con la maternidad, partos por cesárea y complicaciones ginecológicas u obstétricas. En conclusión, aunque el género no define el costo de los procedimientos rutinarios,

si perfila la naturaleza y distribución de los eventos de alto costo, por lo que resulta un atributo valioso para la fase de modelado.

2.5.3. Influencia de la Región Geográfica en los costos

Continuando con el análisis exploratorio bivariado, se examinó la relación entre la zona de residencia del asegurado (*región*) y los costos médicos (*charges*).

El propósito de esta evaluación es identificar si la ubicación geográfica representa un factor de riesgo financiero para la aseguradora, lo cual podría justificar un ajuste regional en el cálculo de las primas.

```
> ggplot(insurance_data, aes(x = region, y = charges)) +  
+   geom_boxplot(fill = "#CD534CFF") +  
+   labs(title = "Charges por región", x = "Región", y = "Charges  
(USD)")
```




Figura 8. Diagrama de caja de los costos médicos distribuidos por región geográfica.

Al observar la Figura 8, el comportamiento de las medianas (representadas por las líneas horizontales centrales) indica que el costo base estándar es prácticamente idéntico en las cuatro

regiones, rondando los 10,000 USD. Esto sugiere que la ubicación geográfica, evaluada de manera aislada, no genera un desplazamiento significativo en la distribución central de los cargos médicos. En otras palabras, un paciente promedio genera gastos similares independientemente de si reside en el noreste o el suroeste del país.

No obstante, la diferencia principal entre las regiones radica en la dispersión de sus valores máximos y en el comportamiento de sus valores atípicos. La región sureste (*southeast*) exhibe el rango intercuartílico más amplio y concentra los cargos médicos más extremos de todo el conjunto de datos, con valores que superan la barrera de los 60,000 USD. Aunque la correlación directa entre la región y los cargos pueda resultar baja en un análisis univariado, es imperativo no eliminar estos registros atípicos. En el contexto del modelado predictivo multivariable, estos altos costos podrían ser explicados por la interacción con otras variables subyacentes, como la concentración poblacional de fumadores o mayores índices de masa corporal en dicha región. Por lo tanto, preservar estos datos es crucial para el entrenamiento íntegro del algoritmo de regresión.

2.5.4. Relación entre Dependientes y Costos Médicos

Avanzando hacia el análisis de las variables numéricas, se evaluó la variable discreta referente al número de dependientes frente a la variable objetivo (*charges*). Para facilitar la visualización y comparación de distribuciones, la variable de dependientes fue tratada temporalmente como factor categórico en la generación del diagrama de caja.

```
> ggplot(insurance_data, aes(x = factor(children), y = charges)) +  
+   geom_boxplot(fill = "#0073C2FF") +  
+   labs(title = "Charges por número de hijos",  
+         x = "Número de hijos", y = "Charges (USD)")
```




Figura 9: Distribución de los cargos médicos en función del número de dependientes cubiertos por la póliza.

El análisis de la Figura 9 revela un comportamiento no lineal y contra intuitivo respecto a la cantidad de dependientes. Al observar las medianas de cada grupo poblacional, se percibe un patrón oscilatorio leve (similar a una onda). Los asegurados sin dependientes (0 hijos) y aquellos con 2, 3 y 4 hijos presentan medianas estadísticamente similares, rondando la franja de los 10,000 USD, mientras que los grupos de 1 y 5 hijos muestran medianas ligeramente inferiores, cercanas a los 9,000 USD.

El aspecto más destacable de esta visualización es el análisis de dispersión máxima y valores atípicos. Paradójicamente, los costos más extremos registrados en el conjunto de datos pertenecen a asegurados con 0, 1 y 3 hijos, alcanzando cifras por encima de los 50,000 e incluso 60,000 USD. Por el contrario, el segmento de familias numerosas (5 dependientes) no presenta registros atípicos de alto costo y su límite superior absoluto es considerablemente menor. Esta anomalía estadística puede explicarse por el sesgo en el volumen de la muestra (la población con 5 hijos es marginal dentro del conjunto de datos) y por un factor demográfico subyacente: los eventos médicos de mayor severidad y costo suelen ocurrir en etapas avanzadas de la vida adulta, período en el cual los dependientes directos ya han

superado la edad máxima de cobertura familiar, retornando al titular de la póliza al grupo de 0 dependientes.

2.5.5. Correlación Multivariable: Edad, Tabaquismo y Costos Médicos

Para profundizar en la interacción de las variables numéricas, se transicionó hacia un análisis de dispersión (*scatter plot*) incorporando una tercera dimensión categórica mediante la codificación por color. El primer modelo visual de esta etapa evalúa la relación simultánea entre la edad del asegurado (*age*), su condición de fumador (*smoker*) y los cargos médicos facturados (*charges*).

```
> ggplot(insurance_data, aes(x = age, y = charges, color = smoker))  
+  
+   geom_point(alpha = 0.5) +  
+   labs(title = "Edad vs Charges", x = "Edad", y = "Charges  
(USD)",  
+         color = "Fumador")
```

La Figura 10 revela patrones estructurales de extrema importancia para la posterior fase de modelado predictivo, evidenciando una fuerte estratificación de los datos en tres corredores visuales diagonales. En primer lugar, el gráfico confirma de manera contundente la influencia del tabaquismo como el factor de mayor peso financiero. Las observaciones correspondientes a los pacientes fumadores se agrupan de forma casi exclusiva en las dos franjas superiores, estableciendo un piso de costos aproximado de 15,000 USD. Por el contrario, la densa acumulación de pacientes no fumadores conforma la franja inferior, con gastos que inician en el límite mínimo del conjunto de datos.

En segundo lugar, al evaluar el comportamiento transversal a lo largo del eje horizontal, se comprueba una tendencia alcista constante y paralela en las tres franjas. Esta pendiente positiva confirma empíricamente que, independientemente del nivel de riesgo derivado del tabaquismo, los costos médicos experimentan un incremento lineal y sostenido conforme avanza la edad del titular. Desde una perspectiva actuarial, este fenómeno refleja el desgaste natural de la salud y el consecuente aumento en el uso de servicios médicos preventivos y correctivos asociados al envejecimiento.




Figura 10. Diagrama de dispersión mostrando la correlación entre la edad y los costos médicos, segmentado por la condición de fumador.

2.5.6. Interacción de Riesgo: Índice de Masa Corporal (BMI) y Tabaquismo

El último modelo visual de la etapa de análisis exploratorio consistió en evaluar la correlación entre el Índice de Masa Corporal y los cargos médicos, manteniendo la segmentación por la condición de fumador. El objetivo de este gráfico de dispersión es identificar si existe una penalización financiera combinada al presentar múltiples factores de riesgo a la salud.

```
> ggplot(insurance_data, aes(x = bmi, y = charges, color = smoker))
+
+   geom_point(alpha = 0.5) +
+   labs(title = "BMI vs Charges", x = "BMI", y = "Charges (USD)",
+         color = "Fumador")
```

Al examinar la Figura 11, se observa una clara bifurcación en el comportamiento de los datos, demostrando que la correlación entre el peso corporal y los gastos médicos está

fuertemente condicionada por el tabaquismo. Entre los pacientes no fumadores (*cluster inferior*), el incremento del BMI no parece detonar un aumento drástico en los costos base; la nube de puntos se mantiene relativamente plana y contenida por debajo de los 15,000 USD, independientemente de si el paciente presenta un peso saludable o grados severos de obesidad.

Sin embargo, el escenario cambia radicalmente al analizar el subgrupo de fumadores. Se detecta un efecto multiplicador (interacción de variables) en los costos cuando convergen el tabaquismo y un índice de masa corporal superior a 30. En este cuadrante específico (superior derecho del gráfico), los cargos médicos sufren una escalada geométrica, partiendo de un piso cercano a los 30,000 USD y extendiéndose hasta superar los 60,000 USD. Esta evidencia analítica confirma que la combinación de tabaquismo y obesidad representa el perfil de máximo riesgo financiero para la aseguradora, un patrón altamente predictivo que el modelo de regresión deberá capturar durante la fase de entrenamiento.




Figura 11. Diagrama de dispersión de la relación entre el BMI y los cargos médicos, codificado por la variable categórica de tabaquismo.

3. Preprocesamiento y Transformación de Datos

Una vez finalizado el Análisis Exploratorio de Datos, la metodología KDD avanza hacia la fase de transformación. El objetivo principal de esta etapa es adecuar la estructura y formato del conjunto de datos para cumplir con los requerimientos matemáticos del algoritmo predictivo, garantizando la convergencia del modelo y evitando sesgos algorítmicos.

3.1. Codificación de Variables Categóricas

La mayoría de los algoritmos de Machine Learning operan exclusivamente sobre espacios numéricos vectoriales. Por consiguiente, se procedió a la conversión de las variables categóricas mediante técnicas de codificación dicotómica. Las variables binarias (*sex* y *smoker*) fueron mapeadas a valores lógicos (0 y 1).

Sin embargo, para la variable multiclase de región geográfica (*region*), se descartó categóricamente la asignación de números enteros secuenciales (1, 2, 3 y 4). Utilizar una codificación ordinal habría inducido un error algorítmico grave: el modelo interpretaría

falsamente una magnitud o jerarquía matemática (asumiendo erróneamente que la región 4 tiene mayor peso o valor que la región 1), cuando en realidad representan ubicaciones nominales sin ningún orden inherente.

Para solucionar esto, se aplicó la técnica de codificación *One-Hot Encoding*, la cual crea una nueva columna binaria independiente para cada zona geográfica. Es importante destacar que se omitió deliberadamente una de las cuatro categorías resultantes. Esta exclusión evita el problema de la multicolinealidad perfecta; matemáticamente, el algoritmo deduce por simple lógica que, si un registro presenta un valor de 0 en las tres regiones codificadas, pertenece de forma implícita a la cuarta región restante (región suroeste).

```
> insurance_data$sex      <- ifelse(insurance_data$sex == "female",  
1, 0)  
> insurance_data$smoker <- ifelse(insurance_data$smoker == "yes",  
1, 0)  
> insurance_data <- insurance_data %>%  
+   mutate(region_northeast = ifelse(region == "northeast", 1, 0),  
+         region_northwest = ifelse(region == "northwest", 1, 0),  
+         region_southeast = ifelse(region == "southeast", 1, 0))  
%>%  
+   select(-region)
```

3.2. Depuración y Escalado de Características

Como parte del aseguramiento de calidad del dato, se ejecutó una validación de integridad para identificar valores nulos (NAs) y registros duplicados:

```
> sum(is.na(insurance_data))  
[1] 0  
> sum(duplicated(insurance_data))  
[1] 1  
> insurance_data <- insurance_data[!duplicated(insurance_data), ]
```

Tras confirmar la ausencia de valores nulos, se procedió a la eliminación de un único registro duplicado, reduciendo la base operativa a 1337 observaciones. Esta decisión metodológica se fundamenta en que las observaciones redundantes no aportan ganancia de información al sistema. Por el contrario, conservar registros idénticos infla artificialmente el peso estadístico de un perfil específico, lo que puede inducir un sesgo algorítmico durante la fase de entrenamiento. Al depurar estos duplicados, se evita que el modelo de regresión incurra en un sobreajuste (*overfitting*) sobre patrones repetidos y se garantiza que aprenda a generalizar correctamente.

Adicionalmente, se evaluó la amplitud empírica (el rango entre el valor mínimo y máximo) de las variables numéricas para determinar la necesidad de aplicar técnicas de normalización. Esta validación es crucial antes de entrenar el modelo: si existen variables con magnitudes muy dispares, el algoritmo de regresión podría interpretar erróneamente que las variables con

números más grandes tienen un mayor peso predictivo. Para evitar que el modelo se sesgue por simples diferencias en las unidades de medida, es indispensable identificar estas asimetrías de escala

```
> range(insurance_data$age) [1] 18 64
> range(insurance_data$bmi)
[1] 15.96 53.13
> range(insurance_data$children)
[1] 0 5
> range(insurance_data$charges)
[1] 1121.874 63770.428
```

La disparidad de magnitudes observada (edades en decenas frente a cargos en decenas de miles) representa un riesgo algorítmico, ya que el modelo podría asignar pesos desproporcionados a las variables con mayor magnitud absoluta. Para mitigar este efecto, se aplicó una técnica de estandarización (*Z-score normalization*) a las variables continuas, centrando su media en 0 y su desviación estándar en 1, y se verificó la nueva estructura del conjunto de datos.

```
> insurance_data_norm <- insurance_data %>%
+   mutate(across(c(age, bmi, children, charges), scale))
> str(insurance_data_norm)
'data.frame': 1337 obs. of  9 variables:
 $ age      : num [1:1337, 1] -1.44 -1.511 -0.799 -0.443 -
0.514 ...
 .. attr(*, "scaled:center")= num 39.2
 .. attr(*, "scaled:scale")= num 14
 $ sex      : num  1 0 0 0 0 1 1 1 0 1 ...
 $ bmi      : num [1:1337, 1] -0.453 0.509 0.383 -1.305 -
0.292 ...
 .. attr(*, "scaled:center")= num 30.7
 .. attr(*, "scaled:scale")= num 6.1
 $ children : num [1:1337, 1] -0.9089 -0.0794 1.5796 -0.9089
-0.9089 ...
 .. attr(*, "scaled:center")= num 1.1
 .. attr(*, "scaled:scale")= num 1.21
 $ smoker   : num  1 0 0 0 0 0 0 0 0 0 ...
 $ charges  : num [1:1337, 1] 0.298 -0.954 -0.729 0.719 -
0.777 ...
 .. attr(*, "scaled:center")= num 13279
 .. attr(*, "scaled:scale")= num 12110
 $ region_northeast: num  0 0 0 0 0 0 0 0 1 0 ...
 $ region_northwest: num  0 0 0 1 1 0 0 1 0 1 ...
 $ region_southeast: num  0 1 1 0 0 1 1 0 0 0 ...
```

La elección de la estandarización *Z-score* responde a la necesidad de que todas las variables contribuyan equitativamente al aprendizaje del modelo, evitando que aquellas con rangos numéricos extensos eclipsen a las de menor escala. Como se puede observar en la estructura resultante del conjunto *insurance_data_norm*, las variables continuas (*age*, *bmi*, *childreny charges*) han perdido su unidad de medida original y ahora se expresan en desviaciones estándar (con valores como -1.44 o 0.298). Adicionalmente, la salida del comando *str()* revela un aspecto técnico vital: R ha conservado los atributos *scaled:center* (la media original del grupo) y *scaled:scale* (la desviación estándar original). Retener estos parámetros es matemáticamente crucial, ya que permitirán realizar la transformación inversa (*des-escalar*) al finalizar el proyecto para presentar las predicciones de costos en su valor monetario real (USD).

3.3. Análisis de Correlación Lineal

Con el conjunto de datos completamente vectorizado (9 variables resultantes), se procedió a calcular la matriz de correlación de Pearson para evaluar la fuerza y dirección de las relaciones lineales simultáneas.

[illegible]

```

-0.32          1.00 region_southeast -0.01
0.27   -0.02 -0.02   0.07
-0.35          -0.35 charges          0.30
0.20    0.07 -0.06   0.79
0.01          -0.04
region_southeast charges age
-0.01    0.30 bmi
0.27    0.20 children
-0.02    0.07 sex
-0.02   -0.06 smoker
0.07    0.79 region_northeast
-0.35    0.01 region_northwest
-0.35   -0.04 region_southeast
1.00    0.07 charges
0.07    1.00

```

Para facilitar la interpretación de estos coeficientes, se generó un correlograma visual mediante la librería *corrplot*.

```

> library(corrplot)
> cor_matrix <- insurance_data %>%
+   select(age, bmi, children, sex, smoker,
+         region_northeast, region_northwest, region_southeast,
+         charges) %>%
+   cor() %>%
+   round(2)
> corrplot(cor_matrix,
+   method      = "color",
+   addCoef.col = "black",
+   tl.col      = "black",
+   tl.srt      = 45,
+   title       = "Heatmap de correlación -- insurance",
+   mar         = c(0, 0, 1, 0))

```

El análisis de esta matriz arroja dos conclusiones fundamentales. Primero, respecto a la variable objetivo, se confirma empíricamente que el tabaquismo (*smoker*) presenta una correlación positiva excepcionalmente fuerte (0.79) con los cargos médicos, poniéndose como el principal atributo predictor de manera aislada. La edad (*age*) y el índice de masa corporal (*bmi*) muestran correlaciones moderadas a bajas (0.30 y 0.20, respectivamente). Es imperativo señalar que una baja correlación lineal no implica irrelevancia predictiva, ya que pueden existir relaciones no lineales o sinergias intervariables que el algoritmo de regresión puede capitalizar.

En segundo lugar, se evaluó la matriz en búsqueda de multicolinealidad entre las variables predictoras independientes. Los coeficientes observados entre ellas son cercanos a cero, lo cual representa el escenario ideal. La ausencia de alta correlación cruzada asegura que cada atributo

aporta información única e independiente al sistema, lo que permite mantener la totalidad de las variables en la arquitectura final del modelo predictivo.




Figura 12. Mapa de calor (Heatmap) de la matriz de correlación de Pearson para todas las variables transformadas.

3.4. Verificación de Multicolinealidad Mediante VIF

Para complementar el análisis visual del correlograma y garantizar la estabilidad matemática de los coeficientes en la futura Regresión Lineal, se calculó el Factor de Inflación de Varianza (VIF, por sus siglas en inglés) utilizando la librería *car*. El objetivo de esta métrica es confirmar empíricamente que ninguna variable independiente sea redundante.

Conceptualmente, el algoritmo del VIF funciona aislando cada variable predictora y creando un modelo de regresión interno para intentar predecir utilizando únicamente al resto de sus compañeras. Si el análisis devuelve un valor de VIF superior a 5, se dictamina la presencia de multicolinealidad severa. Esto significa que dos o más variables están aportando exactamente la misma información al sistema (haciendo la misma función). Mantener variables con alta colinealidad afecta negativamente el rendimiento de la regresión, ya que confunde al modelo al momento de repartir los pesos predictivos y genera cálculos inestables sin aportar valor real.

A continuación, se analizarán los datos devueltos por esta prueba para asegurar que cada característica de nuestro conjunto aporte información estadísticamente única.

```
> library(car)
> modelo_vif <- lm(charges ~ age + bmi + children + sex + smoker +
+                   region_northeast + region_northwest +
region_southeast,
+                   data = insurance_data)
> vif(modelo_vif)
age
bmi      children      sex
smoker
1.016794      1.106742      1.004017
1.008944      1.012100 region_northeast
region_northwest region_southeast
1.525846      1.523624      1.596665
```

Los resultados obtenidos muestran que todas las variables predictoras presentan un VIF cercano a 1 (siendo el valor máximo 1.59 para región southeast). Esta métrica confirma empíricamente la ausencia total de multicolinealidad severa, validando de manera definitiva la idoneidad del conjunto de datos transformado para el entrenamiento del modelo de regresión.

4. Selección y Entrenamiento de Modelos

Tras finalizar el preprocesamiento, la metodología procedió a la etapa de modelado predictivo. Para garantizar la capacidad de generalización de los algoritmos y evitar el sobreajuste (overfitting), se realizó una partición del conjunto de datos. Utilizando la librería *caret*, se extrajo un 70 % de las observaciones (937 registros) para la fase de entrenamiento y se reservó el 30 % restante (400 registros) como conjunto de prueba (test set). Para asegurar la reproducibilidad del experimento, se fijó una semilla aleatoria

```
(set.seed(123)).
> library(rpart)
> library(rpart.plot)
> #División del dataset 70% entrenamiento, 30% prueba
> set.seed(123)
> trainIndex <- createDataPartition(insurance_data$charges, p = 0.7,
list = FALSE)
> train_set <- insurance_data[trainIndex, ]
> test_set <- insurance_data[-trainIndex, ]
```

4.1. Modelo Base: Regresión Lineal Múltiple

El primer enfoque analítico consistió en el entrenamiento de un modelo paramétrico de Regresión Lineal Múltiple. Este algoritmo fue seleccionado como línea base (*baseline*) debido a su alta interpretabilidad matemática y a que la variable objetivo (*charges*) es de naturaleza continua. A diferencia de los modelos de agrupación (*clustering*), que buscan encontrar

similitudes ocultas para segmentar datos sin una etiqueta previa, o los modelos de clasificación, que intentan asignar registros a categorías discretas (como "riesgo alto" o "riesgo bajo"), la regresión lineal tiene como objetivo predecir un valor numérico exacto.

La principal ventaja de optar por una regresión en este escenario es que nos permite cuantificar la relación directa entre las variables. Mientras que un sistema de clasificación nos diría simplemente si un paciente es costoso o no, la regresión lineal nos entrega una ecuación donde cada factor (edad, BMI, tabaquismo) tiene un peso específico medible en dólares. Esto otorga una transparencia que otros modelos más complejos no poseen, permitiendo a la aseguradora entender exactamente cuánto aporta cada año de vida o cada punto de índice de masa corporal al costo final de la prima.

Además, como modelo de aprendizaje supervisado, la regresión lineal destaca por su eficiencia computacional y su capacidad para establecer una tendencia clara. Al ser un modelo de "línea de mejor ajuste", nos permite ver la progresión constante del riesgo: por ejemplo, nos indica que el costo no sube de forma caótica, sino que sigue una trayectoria predecible a medida que el asegurado envejece. Esta estabilidad es lo que la convierte en la herramienta ideal para comparar posteriormente contra algoritmos más flexibles, como los árboles de decisión, y determinar si la complejidad adicional realmente mejora la precisión de nuestras predicciones financieras.

```
> modelo_lineal <- lm(charges ~ age + bmi + children + sex + smoker  
+  
+ region_northeast + region_northwest +  
region_southeast,  
+ data = train_set)
```

Para llevar a cabo el entrenamiento del algoritmo, se utilizó la función *lm()* (Linear Model) en R. La configuración del modelo estableció la variable continua de costos médicos como la variable dependiente (objetivo), mientras que el resto de las características se definieron como variables independientes (predictoras). Es crucial señalar que, de las cuatro regiones geográficas originalmente disponibles, solo se incluyeron tres en la fórmula matemática. Como se explicó previamente en la sección de codificación, omitir una región previene el fenómeno de la multicolinealidad perfecta (la "trampa de la variable ficticia"); el modelo asume por defecto que si un asegurado tiene el valor de 0 en el noreste, noroeste y sureste, automáticamente pertenece a la cuarta región no listada (suroeste). Todo este proceso se ejecutó exclusivamente sobre el subconjunto de entrenamiento para permitir una evaluación imparcial posterior.

```
> summary(modelo_lineal) Call:
```

```
lm(formula = charges ~ age + bmi + children + sex + smoker +
region_northeast + region_northwest + region_southeast, data =
train_set)
```

Residuals:

Min	1Q	Median	3Q	Max
-10266	-3136	-1217	1185	30500

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	-13719.71	1273.73	-10.771	< 2e-16	*** age
254.09	14.64	17.356	< 2e-16	***	bmi
364.60	35.41	10.295	< 2e-16	***	children
437.24	169.03	2.587	0.00984	**	sex
332.02	411.15	0.808	0.41955		smoker
23057.62	517.54	44.552	< 2e-16	***	region_northeast
1151.07	582.84	1.975	0.04857	*	region_northwest
926.54	586.91	1.579	0.11475		region_southeast
251.75	576.14	0.437	0.66224	---	

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 6251 on 928 degrees of freedom

Multiple R-squared: 0.7227, Adjusted R-squared: 0.7203

F-statistic: 302.3 on 8 and 928 DF, p-value: < 2.2e-16

Al evaluar el resumen estadístico (summary) del modelo lineal, se extraen hallazgos determinantes sobre cómo interactúan los factores de salud con los costos médicos. La salida principal nos proporciona dos piezas clave de información: el "Estimate" (Coeficiente) y el "Pr(>|t|)" (Valor P o Significancia). Las tres estrellas (***) junto a variables como age, bmi y smoker indican un nivel de certeza matemática casi absoluto (un Valor P prácticamente de cero). Esto significa que es indudable que la edad, la obesidad y el tabaquismo influyen de manera real en los costos médicos, y no son fruto de una coincidencia en los datos de la muestra. Por el contrario, la variable de género (sex) no obtuvo ninguna estrella, demostrando estadísticamente que ser hombre o mujer, por sí solo, no determina una diferencia constante y generalizada en los costos rutinarios. El modelo lineal expone el peso financiero exacto de cada factor. El hallazgo más abrumador es el coeficiente del tabaquismo (smoker), el algoritmo determinó que, asumiendo que el resto de las condiciones de la persona se mantienen iguales, el simple hecho de ser fumador añade un promedio de \$23,057 USD al costo médico base. Asimismo, se observa que por cada año de edad que cumple el paciente, el costo se incrementa en \$254 USD, y por cada punto adicional en su Índice de Masa Corporal, el gasto sube \$364 USD.

Finalmente, el modelo arrojó un valor R-cuadrado Ajustado (Adjusted R-squared) de 0.7203. Esta métrica general nos indica que nuestra fórmula matemática de Regresión Lineal Múltiple es capaz de explicar y predecir aproximadamente el 72% del comportamiento total de los costos médicos de la aseguradora.

4.2. Modelo Principal: Árbol de Decisión

Dado que en la fase exploratoria se detectó una fuerte interacción multiplicativa entre variables (específicamente entre el tabaquismo y la obesidad), el modelo lineal resultaba insuficiente por su naturaleza estrictamente aditiva. Por ello, se procedió a entrenar un modelo no paramétrico capaz de capturar relaciones no lineales complejas de manera orgánica: un Árbol de Regresión.

```
> modelo_arbol <- rpart(charges ~ age + bmi + children + sex +
+ smoker +
+ region_northeast + region_northwest +
+ region_southeast,
+ data = train_set,
+ method = "anova",
+ control = rpart.control(maxdepth = 5,
+ minsplit = 20))
```

Se utilizó la librería *rpart* especificando el método *anova*. Esta configuración le indica al algoritmo que, en cada paso, debe buscar la variable y el punto de corte que logre la mayor reducción de varianza (es decir, agrupar a los pacientes con costos más similares). Para controlar la complejidad de la arquitectura y evitar el sobreajuste (*overfitting*), se limitó la profundidad del árbol a 5 niveles lógicos (*maxdepth* = 5) y se exigió un mínimo de 20 observaciones para permitir una nueva división nodal (*minsplit* = 20).

```
> rpart.plot(modelo_arbol,
+ type = 4,
+ extra = 101,
+ under = TRUE,
+ main = "Árbol de decisión -- charges")
```

Árbol de decisión — charges




Figura 13. Estructura gráfica del modelo Árbol de Decisión para la predicción de costos.

Al analizar la estructura gráfica del modelo resultante, podemos trazar de manera transparente las reglas lógicas que el algoritmo descubrió por sí solo para segmentar el riesgo financiero de los asegurados:

1. **El Nodo Raíz (Costo Promedio):** En la cima del árbol, observamos que el 100% de la muestra de entrenamiento ($n=937$) tiene un costo médico promedio que ronda los **\$13,000 USD** ($13e+3$).
2. **El Discriminador Principal (Tabaquismo):** El algoritmo determinó matemáticamente que la decisión más crítica para separar los costos es si el paciente fuma o no ($\text{smoker} = 0$ o $\text{smoker} = 1$). Esta única regla divide a la población en dos realidades financieras distintas, los no fumadores (el 80% de la muestra) bajan su costo promedio a **\$8,680 USD**, mientras que los fumadores (el 20% de la muestra) lo disparan a **\$31,000 USD**.
3. **El Perfil de Bajo Riesgo (Rama Izquierda):** Si el paciente no es fumador, el siguiente factor más importante para determinar su costo es la edad ($\text{age} < 43$). Los adultos jóvenes no fumadores representan el clúster más grande y económico para la aseguradora (45% de la población, con un costo de apenas **\$5,595 USD**). Los no

fumadores mayores de 43 años presentan un costo predeciblemente más alto (\$13,000 USD), reflejando el desgaste natural de la salud.

4. **El Perfil Catastrófico (Rama Derecha):** El hallazgo más valioso de este modelo se observa en el subgrupo de fumadores. Una vez que se sabe que el paciente fuma, la edad pasa a segundo plano y el algoritmo corta los datos usando el Índice de Masa Corporal ($bmi < 30$). Los fumadores que no tienen obesidad clínica representan un costo de \$21,000 USD. Sin embargo, los fumadores que además padecen obesidad ($bmi \geq 30$) conforman el perfil de máximo riesgo: este 10% de la población registra un costo promedio exorbitante de \$42,000 USD.

5. Evaluación y Comparación de Rendimiento

Con las arquitecturas de ambos algoritmos matemáticamente definidas, la metodología avanzó hacia la fase de inferencia. Para garantizar la validez del experimento y comprobar la capacidad de generalización de los modelos, las predicciones se ejecutaron exclusivamente sobre el conjunto de prueba aislado (test set), el cual contiene el 30 por ciento de las observaciones originales que los algoritmos jamás habían visto durante su fase de entrenamiento..

Para evaluar de manera objetiva el rendimiento predictivo, se calcularon tres métricas estándar fundamentales en los problemas de regresión. Primero se obtuvo el Error Absoluto Medio (MAE), el cual mide la diferencia promedio entre el costo predicho por el algoritmo y el costo real facturado, expresado directamente en dólares. Segundo, se calculó la Raíz del Error Cuadrático Medio (RMSE), una métrica que al elevar los errores al cuadrado antes de promediarlos penaliza de forma severa las equivocaciones grandes; en el sector asegurador, esto es vital para identificar si un modelo está fallando catastróficamente al predecir a los pacientes más costosos. Finalmente, se extrajo el Coeficiente de Determinación (R cuadrado), el cual indica la proporción de la varianza total en los costos médicos que el modelo es capaz de explicar, donde un valor más cercano a uno representa una predicción perfecta.

```
> cat(sprintf("%-25s %10s %10s %10s\n", "Modelo", "MAE", "RMSE",  
"R²"))  
Modelo                MAE      RMSE      R²  
> cat(sprintf("%-25s %10.2f %10.2f %10.4f\n", "Regresión Lineal",  
+          mae_lineal, rmse_lineal, r2_lineal))  
Regresión Lineal      4160.66   5655.73   0.8085  
> cat(sprintf("%-25s %10.2f %10.2f %10.4f\n", "Árbol de Decisión",  
+          mae_arbol, rmse_arbol, r2_arbol))  
Árbol de Decisión     3251.90   4688.57   0.8667
```

Al contrastar los resultados arrojados por el sistema, la superioridad del modelo no paramétrico, es decir, el Árbol de Decisión, es sustancial en todas las dimensiones evaluadas. El modelo lineal base logró un R cuadrado de 0.8085, lo que implica que puede explicar cerca del 81 por ciento de la varianza en los datos nuevos. Sin embargo, su precisión financiera se ve

comprometida al presentar un desfase promedio (MAE) de 4,160.66 USD por paciente. Por su parte, el Árbol de Decisión elevó el poder explicativo a un R cuadrado de 0.8667, traducándose en casi el 87 por ciento de la varianza explicada, y logró reducir el error promedio a 3,251.90 USD. Esto representa un ahorro de casi 900 USD en margen de error por cada predicción realizada.

Más importante aún es el comportamiento del error cuadrático. La Regresión Lineal muestra un RMSE de 5,655.73 USD, lo que sugiere que el modelo comete errores de gran magnitud en ciertos perfiles de riesgo. El Árbol de Decisión logró reducir este castigo algorítmico a 4,688.57 USD, demostrando ser un sistema mucho más robusto frente a los valores atípicos y los siniestros de alto costo.

Para comprender el porqué de esta diferencia matemática, se generaron gráficos de dispersión contrastando los valores reales facturados en el eje horizontal frente a los predichos por los algoritmos en el eje vertical. En estas visualizaciones se integró una línea punteada que representa la función de identidad geométrica; cualquier punto que se sitúe exactamente sobre esta línea representa una predicción perfecta con error nulo.




Figura 14. Comparativa de dispersión de valores reales frente a los predichos sobre el conjunto de prueba

El análisis visual expone claramente la debilidad algorítmica de la Regresión Lineal para este dominio específico de negocio. Al observar su gráfico, se nota que el modelo intenta ajustar una tendencia recta continua. Esto funciona relativamente bien para los pacientes sanos de bajo costo que se acumulan en la parte inferior izquierda, pero conforme los costos reales aumentan, las predicciones se dispersan caóticamente alejándose de la línea de ajuste perfecto. El modelo lineal fracasa al intentar predecir a los pacientes más caros porque no entiende las sinergias de riesgo, asumiendo erróneamente que fumar y tener obesidad suman costos de forma completamente independiente.

En contraste, el gráfico del Árbol de Decisión exhibe un comportamiento escalonado en franjas horizontales. Debido a que el árbol segmenta a la población en agrupaciones a través de decisiones jerárquicas, no predice una línea continua, sino que asigna a cada paciente el costo promedio de su perfil de riesgo exacto. Visualmente, estas agrupaciones logran interceptar la línea de predicción perfecta con mucha mayor exactitud, especialmente en las franjas superiores que superan los 40,000 USD.

El Árbol de Decisión supera a la Regresión Lineal porque logró capturar matemáticamente la fuerte interacción multiplicativa entre el tabaquismo y la obesidad. En virtud de estos resultados empíricos, y dada su mayor precisión financiera y mitigación de errores catastróficos, el Árbol de Decisión es seleccionado en definitiva como el modelo óptimo de esta primera fase del proyecto.

6. Conclusión

El presente proyecto aplicó de manera integral la metodología de Descubrimiento de Conocimiento en Bases de Datos (*KDD*) sobre el Insurance Dataset, con el objetivo de construir un modelo predictivo robusto para la estimación de costos médicos en el sector asegurador. A lo largo de las cinco etapas documentadas, se obtuvieron hallazgos relevantes tanto desde la perspectiva analítica como desde la del negocio.

Durante la fase de análisis exploratorio, se confirmó que la distribución de la variable objetivo (*charges*) presenta una marcada asimetría positiva y un comportamiento bimodal, evidencia preliminar de la existencia de al menos dos perfiles de riesgo diferenciados dentro de la cartera de clientes. El análisis bivariado consolidó este hallazgo, el tabaquismo (*smoker*) emerge como el predictor de mayor peso individual, con una correlación de Pearson de 0,79 respecto a los cargos médicos. Adicionalmente, se identificó un efecto multiplicador crítico cuando el tabaquismo converge con un índice de masa corporal superior a 30, configurando el perfil de máximo riesgo financiero para la aseguradora.

En la fase de preprocesamiento, se verificó la calidad e integridad del conjunto de datos, se eliminó un registro duplicado, se codificaron correctamente las variables categóricas mediante técnicas de one-hot encoding y se descartó la presencia de multicolinealidad severa a través del cálculo del Factor de Inflación de Varianza (VIF), con un valor máximo de 1,597, muy por debajo del umbral crítico de 5.

Respecto a la fase de modelado, se entrenaron y compararon dos algoritmos, una Regresión Lineal Múltiple como línea base y un Árbol de Decisión como modelo principal. La evaluación sobre el conjunto de prueba (30 % de los datos, $n = 400$) demostró la superioridad del Árbol de Decisión en todas las métricas calculadas alcanzó un coeficiente de determinación $R^2 = 0,8667$, un Error Absoluto Medio de \$3,251.90 USD y una Raíz del Error Cuadrático Medio de \$4,688.57 USD, frente a un $R^2 = 0,8085$ y un MAE de \$4,160.66 USD del modelo lineal. Esta ventaja se atribuye a la capacidad del árbol para capturar las relaciones no lineales e interacciones entre variables que la regresión lineal no puede modelar de forma nativa.